Universidad Veracruzana

Maestría en Inteligencia Artificial

Visión por Computadora

Tarea 12. Clasificación binaria de imagenes de gusanos mediante una red neuronal convolucional en MATLAB

Ángel García Báez

Profesor: Dr. Héctor Acosta Mesa

June 11, 2025

Contents

1 Objetivo de la práctica

Para la presente practica, se cuenta con un conjunto de 93 imágenes en formato .tif de gusanos, de los cuales 48 están etiquetados como "vivos" y 45 están identificados como muertos. A continuación se muestra una muestra de como son estas imágenes.

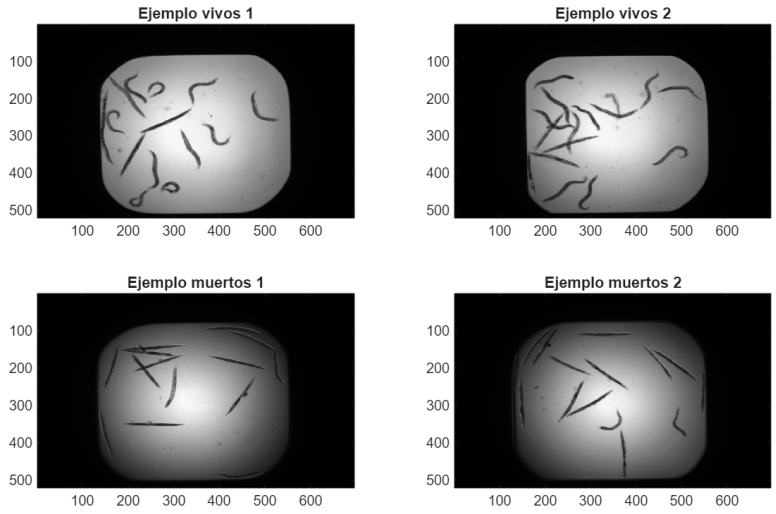

Muestra de gusanos vivos y muertos.

Se observan claras diferencias entre el comportamiento de ambas imagenes, para el caso de los gusanos vivos, se percibe movimientos y formas curvas. Para el caso de los gusanos muertos, se perciben en posiciones rectas.

Una vez entendido esto, lo que se pide hacer es lo siguiente:

- Se pide implementar una metodología usando redes neuronales convolucionales para llevar a cabo la clasificación binaria (vivos o muertos) de las imágenes.
- Se espera lograr un mínimo de buena clasificación del 90%

2 Metodología

2.1 Dividir la base de datos

En primera instancia, se toma el conjunto de las 93 imágenes y se divide en 2 partes siguiendo la proporción 80-20. El 80% de los datos (77 imágenes) que se seleccionaron de forma al azar, fueron utilizadas para entrenar al modelo de red neuronal mientras que el restante 20% (19 imágenes) fueron utilizadas como prueba. Cabe mencionar que se fijo la semilla 64 para replicabilidad.

2.2 Propuesta para construir la red neuronal

Para llevar a cabo la clasificación automática de imágenes de gusanos vivos y muertos se pusieron en practica los conceptos expuestos en Wu (2017) como introducción a las redes convolucionales en matlab. Se desarrolló una red neuronal convolucional (CNN) en MATLAB como sigue:

- Como pre-procesamiento se tomaron todas las imágenes de gusanos vivos y muertos, se estandarizaron en un formato de 100x100 píxeles en escala de grises con ayuda de la función augmentedImageDatastore() de MATLAB.
- La arquitectura de la red comienza pidiendo una capa de entrada que recibe las imágenes en escala de grises de tamaño 100x100.
- Se agregan dos bloques convolucionales, cada uno compuesto por una capa de convolución 2D que detecta patrones espaciales locales mediante filtros 2D.
- Se aplica una capa de normalización por lotes que estabiliza el aprendizaje y acelera la convergencia.
- Se agrega una capa con la función de activación ReLU que introduce no linealidad al modelo.
- Cada bloque se completa con una capa de submuestreo con maxPooling2dLayer que va reduciendo la dimensionalidad espacial y conservando las características más importantes.
- Se incluye una capa completamente conectada al final de la extracción de caracteristicas con 2 neuronas de salida, correspondientes a las clases de los gusanos.

- Se usa una capa softmax para convertir las salidas en probabilidades que finalmente terminan en una capa de clasificación que permiten a la red decir si una imagen presenta gusanos vivos o no.

El entrenamiento de la red se realizó con el algoritmo de optimización Adam, configurando un máximo de 20 épocas y una frecuencia de validación cada 5 iteraciones para monitorear el rendimiento. Se habilitó la visualización del progreso del entrenamiento mediante gráficos, lo que permitió observar la evolución de la precisión y la pérdida. Esta configuración balancea simplicidad y eficiencia, siendo adecuada para un problema binario de clasificación con imágenes de tamaño reducido y características visuales distinguibles.

3 Resultados

3.1 Proceso de entrenamiento de la red

A continuación se muestra el comportamiento de la red durante su entrenamiento hasta lograr una convergencia estable:

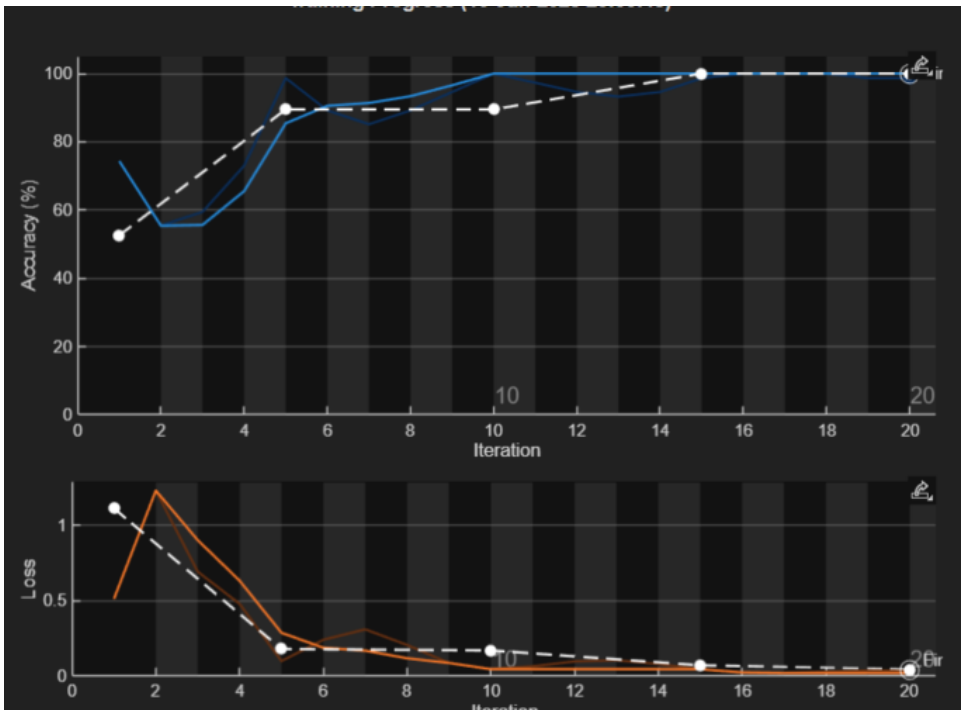

Figure 1: Proceso de entrenamiento.

El gráfico muestra el desempeño de la red neuronal con el conjunto de prueba a lo así como la función de perdida a lo largo de 20 iteraciones.

3.2 Matriz de confusión

A continuación se muestra la matriz de confusión que reporta la red neuronal al clasificar el conjunto de prueba.

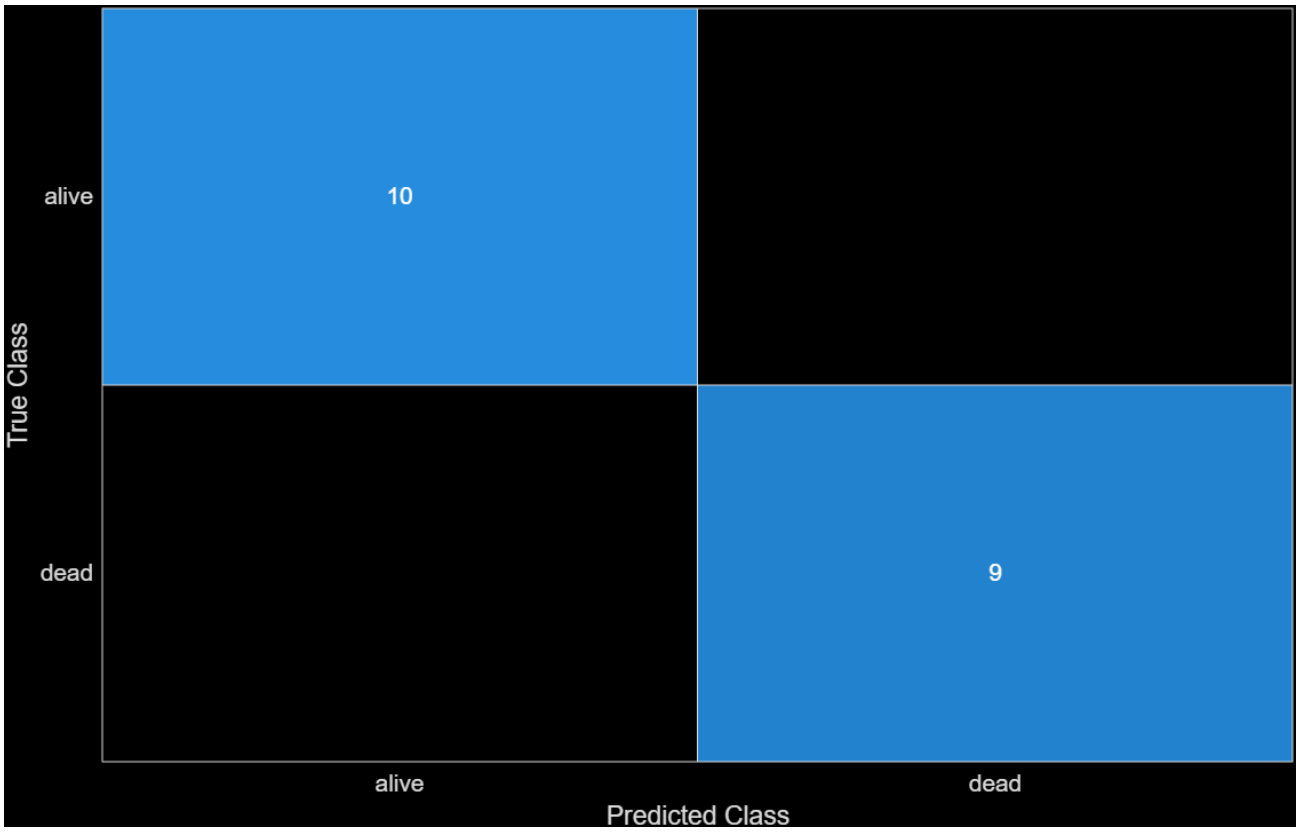

Figure 2: Matriz de confusión.

Se observa que la red tiene un desempeño perfecto para predecir correctamente al conjunto de prueba, logrando una precisión del 100%.

4 Conclusiones

Después de haber realizado la implementación del problema y obtener los resultados esperados (una clasificación mayor al 90%) cabe reflexionar lo importante que es la calibración de la red neuronal, puesto que su funcionamiento es enteramente de caja negra. Se puede llegar a un resultado satisfactorio y saber que operaciones se estan aplicando, pero la calibración de los pesos de dicha red y la forma en que extraer caracteristicas a un nivel tan abstracto, resulta un total misterio que pese a ser bueno en su trabajo, resulta poco explicable.

5 Referencias

References

Wu, J. (2017). Introduction to convolutional neural networks. *National Key Lab for Novel Software Technology. Nanjing University. China*, 5(23):495.

6 Anexos

6.1 Implementación en MATLAB de la red convolucional

```
%% Mostrar una muestra de imagenes %%
rutae = "WormData.csv";
labelsTable = readtable(rutae);
% Filtrar las imágenes 'alive'
aliveFiles = labelsTable(strcmp(labelsTable.Status, 'alive'), :);
% Filtrar las imágenes 'dead'
deadFiles = labelsTable(strcmp(labelsTable.Status, 'dead'), :);
%% Seleccionar las primeras 2 de cada tipo %%
base = "WormImages\";
subplot(2,2,1)
imagesc(imread(strcat(base,aliveFiles.File{1})))
title("Ejemplo vivos 1")
subplot(2,2,2)
imagesc(imread(strcat(base,aliveFiles.File{2})))
title("Ejemplo vivos 2")
subplot(2,2,3)
imagesc(imread(strcat(base,deadFiles.File{1})))
title("Ejemplo muertos 1")
subplot(2,2,4)
imagesc(imread(strcat(base,deadFiles.File{2})))
title("Ejemplo muertos 2")
colormap("gray")
%% Cargar las imagenes %%
ruta = "WormImages\wormA01.tif"
img = imread(ruta);
%imshow(img)
imagesc(img)
colormap("gray")
% Etiquetas %
rutae = "WormData.csv";
labelsTable = readtable(rutae);
labelsTable;
%% Cargar todas las imagenes %%
imageFolder = "WormImages";
% Crear un arreglo de imagenDatastore
imds = imageDatastore(fullfile(imageFolder), ...
'IncludeSubfolders', false, ...
```

```
'FileExtensions', '.tif', ...
'LabelSource', 'none');
% Agregar las etiquetas al datastore
imds.Labels = categorical(labelsTable.Status);
%% Dividir los datos %%
rng(64)
[imdsTrain, imdsValidation] = splitEachLabel(imds, 0.8, 'randomized');
% Revisar que sale de aqui
imdsTrain
% Re definir el tamaño de las imagenes
imageSize = [100 100 1]; % Usa 3 en lugar de 1 si es RGB
augmentedTrain = augmentedImageDatastore(imageSize, imdsTrain);
augmentedVal = augmentedImageDatastore(imageSize, imdsValidation);
layers = [
imageInputLayer(imageSize)
convolution2dLayer(3, 8, 'Padding', 'same')
batchNormalizationLayer
reluLayer
maxPooling2dLayer(2, 'Stride', 2)
convolution2dLayer(3, 16, 'Padding', 'same')
batchNormalizationLayer
reluLayer
maxPooling2dLayer(2, 'Stride', 2)
fullyConnectedLayer(2)
softmaxLayer
classificationLayer
];
% Entrenar a la red %%
options = trainingOptions('adam', ...
'MaxEpochs', 20, ...
'ValidationData', augmentedVal, ...
'ValidationFrequency', 5, ...
'Verbose', true, ...
'Plots', 'training-progress');
net = trainNetwork(augmentedTrain, layers, options);
%% Evaluar red %%
predictedLabels = classify(net, augmentedVal);
valLabels = imdsValidation.Labels;
accuracy = sum(predictedLabels == valLabels)/numel(valLabels);
fprintf('Precisión en validación: %.2f%%\n', accuracy * 100);
```

```
78  confusionchart(imdsValidation.Labels,predictedLabels)
79  %% Evaluar red por fuera %%
80  A = classify(net, augmentedVal)
81  %%
82  augmentedVal.NumObservations
83  %% Leer la primera imagen del conjunto de validación
84  img = readimage(imdsValidation, 19);
85  % Mostrar la imagen
86  imagesc(img);
87  colormap("gray")
88  title('Imagen de validación');
89  % Redimensionar (si es necesario)
90  imageSize = [100 100 1];  % Cambia a [100 100 3] si es RGB
91  imgResized = imresize(img, imageSize(1:2));
92  imagesc(imgResized);
93  colormap("gray")
94  % Clasificar la imagen con la red entrenada %%
95  predictedLabel = classify(net, imgResized);
96  % Mostrar predicción
97  disp(['La red predice: ' char(predictedLabel)]);
98
```